
讲堂 > Java核心技术36讲 > 文章详情

第9讲丨对比Hashtable、HashMap、TreeMap有什么不同?

2018-05-24 杨晓峰



第9讲 | 对比Hashtable、HashMap、TreeMap有什么不同? 朗读人: 黄洲君 12'16" | 5.62M

Map 是广义 Java 集合框架中的另外一部分,HashMap 作为框架中使用频率最高的类型之一,它本身以及相关类型自然也是面试考察的热点。

今天我要问你的问题是,对比 Hashtable、HashMap、TreeMap 有什么不同?谈谈你对 HashMap 的掌握。

典型回答

Hashtable、HashMap、TreeMap 都是最常见的一些 Map 实现,是以键值对的形式存储和操作数据的容器类型。

Hashtable 是早期 Java 类库提供的一个<u>哈希表</u>实现,本身是同步的,不支持 null 键和值,由于同步导致的性能开销,所以已经很少被推荐使用。

HashMap 是应用更加广泛的哈希表实现,行为上大致上与 HashTable 一致,主要区别在于 HashMap 不是同步的,支持 null 键和值等。通常情况下,HashMap 进行 put 或者 get 操

作,可以达到常数时间的性能,所以它是绝大部分利用键值对存取场景的首选,比如,实现一个 用户 ID 和用户信息对应的运行时存储结构。

TreeMap 则是基于红黑树的一种提供顺序访问的 Map,和 HashMap 不同,它的 get、put、remove 之类操作都是 O (log(n))的时间复杂度,具体顺序可以由指定的 Comparator 来决定,或者根据键的自然顺序来判断。

考点分析

上面的回答,只是对一些基本特征的简单总结,针对 Map 相关可以扩展的问题很多,从各种数据结构、典型应用场景,到程序设计实现的技术考量,尤其是在 Java 8 里,HashMap 本身发生了非常大的变化,这些都是经常考察的方面。

很多朋友向我反馈,面试官似乎钟爱考察 HashMap 的设计和实现细节,所以今天我会增加相应的源码解读,主要专注于下面几个方面:

- 理解 Map 相关类似整体结构,尤其是有序数据结构的一些要点。
- 从源码去分析 HashMap 的设计和实现要点,理解容量、负载因子等,为什么需要这些参数,如何影响 Map 的性能,实践中如何取舍等。
- 理解树化改造的相关原理和改进原因。

除了典型的代码分析,还有一些有意思的并发相关问题也经常会被提到,如 HashMap 在并发环境可能出现无限循环占用 CPU、size 不准确等诡异的问题。


我认为这是一种典型的使用错误,因为 HashMap 明确声明不是线程安全的数据结构,如果忽略这一点,简单用在多线程场景里,难免会出现问题。

理解导致这种错误的原因,也是深入理解并发程序运行的好办法。对于具体发生了什么,你可以参考这篇很久以前的分析,里面甚至提供了示意图,我就不再重复别人写好的内容了。

知识扩展

1.Map 整体结构

首先,我们先对 Map 相关类型有个整体了解, Map 虽然通常被包括在 Java 集合框架里,但是其本身并不是狭义上的集合类型(Collection),具体你可以参考下面这个简单类图。



Hashtable 比较特别,作为类似 Vector、Stack 的早期集合相关类型,它是扩展了 Dictionary 类的,类结构上与 HashMap 之类明显不同。

HashMap 等其他 Map 实现则是都扩展了 AbstractMap, 里面包含了通用方法抽象。不同 Map 的用途,从类图结构就能体现出来,设计目的已经体现在不同接口上。

大部分使用 Map 的场景,通常就是放入、访问或者删除,而对顺序没有特别要求,HashMap 在这种情况下基本是最好的选择。HashMap 的性能表现非常依赖于哈希码的有效性,请务必掌握 hashCode 和 equals 的一些基本约定,比如:

- equals 相等, hashCode 一定要相等。
- 重写了 hashCode 也要重写 equals。
- hashCode 需要保持一致性,状态改变返回的哈希值仍然要一致。
- equals 的对称、反射、传递等特性。

这方面内容网上有很多资料,我就不在这里详细展开了。

针对有序 Map 的分析内容比较有限,我再补充一些,虽然 LinkedHashMap 和 TreeMap 都可以保证某种顺序,但二者还是非常不同的。

• LinkedHashMap 通常提供的是遍历顺序符合插入顺序,它的实现是通过为条目(键值对) 维护一个双向链表。注意,通过特定构造函数,我们可以创建反映访问顺序的实例,所谓的 put、get、compute 等,都算作"访问"。

这种行为适用于一些特定应用场景,例如,我们构建一个空间占用敏感的资源池,希望可以自动将最不常被访问的对象释放掉,这就可以利用 LinkedHashMap 提供的机制来实现,参考下面的示例:

```
■ 复制代码
1 import java.util.LinkedHashMap;
2 import java.util.Map;
   public class LinkedHashMapSample {
       public static void main(String[] args) {
           LinkedHashMap<String, String> accessOrderedMap = new LinkedHashMap<>(16, 0.75F, true){
               @Override
               protected boolean removeEldestEntry(Map.Entry<String, String> eldest) { // 实现自定义
8
                   return size() > 3;
               }
10
           };
           accessOrderedMap.put("Project1", "Valhalla");
12
           accessOrderedMap.put("Project2", "Panama");
           accessOrderedMap.put("Project3", "Loom");
13
           accessOrderedMap.forEach( (k,v) -> {
               System.out.println(k +":" + v);
15
           });
           // 模拟访问
17
           accessOrderedMap.get("Project2");
           accessOrderedMap.get("Project2");
           accessOrderedMap.get("Project3");
           System.out.println("Iterate over should be not affected:");
           accessOrderedMap.forEach( (k,v) -> {
               System.out.println(k +":" + v);
           });
           // 触发删除
           accessOrderedMap.put("Project4", "Mission Control");
26
27
           System.out.println("Oldest entry should be removed:");
           accessOrderedMap.forEach((k,v)-> {// 遍历顺序不变
               System.out.println(k +":" + v);
29
           });
       }
31
32 }
```

对于 TreeMap,它的整体顺序是由键的顺序关系决定的,通过 Comparator或
 Comparable(自然顺序)来决定。

我在上一讲留给你的思考题提到了,构建一个具有优先级的调度系统的问题,其本质就是个典型的优先队列场景,Java 标准库提供了基于二叉堆实现的 PriorityQueue,它们都是依赖于同一种排序机制,当然也包括 TreeMap 的马甲 TreeSet。

类似 hashCode 和 equals 的约定,为了避免模棱两可的情况,自然顺序同样需要符合一个约定,就是 compareTo 的返回值需要和 equals 一致,否则就会出现模棱两可情况。

我们可以分析 TreeMap 的 put 方法实现:

```
■ 复制代码
 1 public V put(K key, V value) {
        Entry\langle K, V \rangle t = ...
 3
        cmp = k.compareTo(t.key);
        if (cmp < 0)
 4
            t = t.left;
       else if (cmp > 0)
            t = t.right;
 7
        else
9
            return t.setValue(value);
            // ...
10
11
       }
```


从代码里,你可以看出什么呢? 当我不遵守约定时,两个不符合唯一性(equals)要求的对象被当作是同一个(因为,compareTo返回0),这会导致歧义的行为表现。

2.HashMap 源码分析

前面提到,HashMap 设计与实现是个非常高频的面试题,所以我会在这进行相对详细的源码解读,主要围绕:

- HashMap 内部实现基本点分析。
- 容量(capacity)和负载系数(load factor)。
- 树化。

首先,我们来一起看看 HashMap 内部的结构,它可以看作是数组(Node<K,V>[] table)和链表结合组成的复合结构,数组被分为一个个桶(bucket),通过哈希值决定了键值对在这个数组的寻址;哈希值相同的键值对,则以链表形式存储,你可以参考下面的示意图。这里需要注意的是,如果链表大小超过阈值(TREEIFY_THRESHOLD, 8),图中的链表就会被改造为树形结构。



从非拷贝构造函数的实现来看,这个表格(数组)似乎并没有在最初就初始化好,仅仅设置了一些初始值而已。

所以,我们深刻怀疑,HashMap 也许是按照 lazy-load 原则,在首次使用时被初始化(拷贝构造函数除外,我这里仅介绍最通用的场景)。既然如此,我们去看看 put 方法实现,似乎只有一个 putVal 的调用:

```
1 public V put(K key, V value) {
2    return putVal(hash(key), key, value, false, true);
3 }
```

看来主要的密码似乎藏在 putVal 里面,到底有什么秘密呢?为了节省空间,我这里只截取了 putVal 比较关键的几部分。

```
1 final V putVal(int hash, K key, V value, boolean onlyIfAbent,
2 boolean evit) {
3 Node<K,V>[] tab; Node<K,V> p; int , i;
4 if ((tab = table) == null || (n = tab.length) = 0)
5 n = (tab = resize()).legth;
```

```
if ((p = tab[i = (n - 1) \& hash]) == ull)
 7
           tab[i] = newNode(hash, key, value, nll);
 8
       else {
9
           // ...
           if (binCount >= TREEIFY_THRESHOLD - 1) // -1 for first
10
              treeifyBin(tab, hash);
12
           // ...
13
        }
14 }
15
```

从 putVal 方法最初的几行, 我们就可以发现几个有意思的地方:

- 如果表格是 null, resize 方法会负责初始化它, 这从 tab = resize() 可以看出。
- resize 方法兼顾两个职责,创建初始存储表格,或者在容量不满足需求的时候,进行扩容 (resize)。
- 在放置新的键值对的过程中,如果发生下面条件,就会发生扩容。

```
1 if (++size > threshold)
2 resize();
```

• 具体键值对在哈希表中的位置 (数组 index) 取决于下面的位运算:

```
1 i = (n - 1) & hash
```

仔细观察哈希值的源头,我们会发现,它并不是 key 本身的 hashCode,而是来自于 HashMap 内部的另外一个 hash 方法。注意,为什么这里需要将高位数据移位到低位进行异或 运算呢?这是因为有些数据计算出的哈希值差异主要在高位,而 HashMap 里的哈希寻址是忽 略容量以上的高位的,那么这种处理就可以有效避免类似情况下的哈希碰撞。

```
1 static final int hash(Object kye) {
2    int h;
3    return (key == null) ? 0 : (h = key.hashCode()) ^ (h >>>16;
4 }
```

• 我前面提到的链表结构(这里叫 bin),会在达到一定门限值时,发生树化,我稍后会分析为什么 HashMap 需要对 bin 进行处理。

可以看到, putVal 方法本身逻辑非常集中, 从初始化、扩容到树化, 全部都和它有关, 推荐你阅读源码的时候, 可以参考上面的主要逻辑。

我进一步分析一下身兼多职的 resize 方法,很多朋友都反馈经常被面试官追问它的源码设计。

```
■ 复制代码
1 final Node<K,V>[] resize() {
       // ...
       else if ((newCap = oldCap << 1) < MAXIMUM_CAPACIY &&
                   oldCap >= DEFAULT_INITIAL_CAPAITY)
           newThr = oldThr << 1; // double there</pre>
7
       else if (oldThr > 0) // initial capacity was placed in threshold
           newCap = oldThr;
8
9
       else {
           // zero initial threshold signifies using defaultsfults
10
           newCap = DEFAULT_INITIAL_CAPAITY;
12
           newThr = (int)(DEFAULT_LOAD_ATOR* DEFAULT_INITIAL_CAPACITY;
13
14
       if (newThr ==0) {
           float ft = (float)newCap * loadFator;
15
           newThr = (newCap < MAXIMUM_CAPACITY && ft < (float)MAXIMUM_CAPACITY ?(int)ft : Integer.M</pre>
16
17
       }
       threshold = neThr;
18
19
       Node<K,V>[] newTab = (Node<K,V>[])new Node[newap];
       table = n;
       // 移动到新的数组结构 e 数组结构
22
23
```

依据 resize 源码,不考虑极端情况(容量理论最大极限由 MAXIMUM_CAPACITY 指定,数值为 1<<30,也就是 2 的 30 次方),我们可以归纳为:

- 门限值等于(负载因子)x(容量),如果构建 HashMap 的时候没有指定它们,那么就是依据相应的默认常量值。
- 门限通常是以倍数进行调整 (newThr = oldThr << 1), 我前面提到, 根据 putVal 中的逻辑, 当元素个数超过门限大小时,则调整 Map 大小。
- 扩容后,需要将老的数组中的元素重新放置到新的数组,这是扩容的一个主要开销来源。
- 3. 容量、负载因子和树化

前面我们快速梳理了一下 HashMap 从创建到放入键值对的相关逻辑,现在思考一下,为什么我们需要在乎容量和负载因子呢?

这是因为容量和负载系数决定了可用的桶的数量,空桶太多会浪费空间,如果使用的太满则会严重影响操作的性能。极端情况下,假设只有一个桶,那么它就退化成了链表,完全不能提供所谓常数时间存的性能。

既然容量和负载因子这么重要,我们在实践中应该如何选择呢?

如果能够知道 HashMap 要存取的键值对数量,可以考虑预先设置合适的容量大小。具体数值 我们可以根据扩容发生的条件来做简单预估,根据前面的代码分析,我们知道它需要符合计算条 件:

```
1 负载因子 * 容量 > 元素数量
2
```

所以,预先设置的容量需要满足,大于"预估元素数量/负载因子",同时它是2的幂数,结论已经非常清晰了。

而对于负载因子, 我建议:

- 如果没有特别需求,不要轻易进行更改,因为 JDK 自身的默认负载因子是非常符合通用场景的需求的。
- 如果确实需要调整,建议不要设置超过 0.75 的数值,因为会显著增加冲突,降低 HashMap的性能。
- 如果使用太小的负载因子,按照上面的公式,预设容量值也进行调整,否则可能会导致更加 频繁的扩容,增加无谓的开销,本身访问性能也会受影响。

我们前面提到了树化改造,对应逻辑主要在 putVal 和 treeifyBin 中。

上面是精简过的 treeifyBin 示意,综合这两个方法,树化改造的逻辑就非常清晰了,可以理解为,当 bin 的数量大于 TREEIFY_THRESHOLD 时:

- 如果容量小于 MIN_TREEIFY_CAPACITY, 只会进行简单的扩容。
- 如果容量大于 MIN_TREEIFY_CAPACITY ,则会进行树化改造。

那么,为什么 HashMap 要树化呢?

本质上这是个安全问题。因为在元素放置过程中,如果一个对象哈希冲突,都被放置到同一个桶里,则会形成一个链表,我们知道链表查询是线性的,会严重影响存取的性能。

而在现实世界,构造哈希冲突的数据并不是非常复杂的事情,恶意代码就可以利用这些数据大量与服务器端交互,导致服务器端 CPU 大量占用,这就构成了哈希碰撞拒绝服务攻击,国内一线互联网公司就发生过类似攻击事件。

今天我从 Map 相关的几种实现对比,对各种 Map 进行了分析,讲解了有序集合类型容易混淆的地方,并从源码级别分析了 HashMap 的基本结构,希望对你有所帮助。

一课一练

关于今天我们讨论的题目你做到心中有数了吗?留一道思考题给你,解决哈希冲突有哪些典型方法呢?

请你在留言区写写你对这个问题的思考,我会选出经过认真思考的留言,送给你一份学习鼓励金,欢迎你与我一起讨论。

你的朋友是不是也在准备面试呢?你可以"请朋友读",把今天的题目分享给好友,或许你能帮到他。



版权归极客邦科技所有,未经许可不得转载

写留言

精选留言



凸 51

解决哈希冲突的常用方法有:

开放定址法

基本思想是: 当关键字key的哈希地址p=H(key)出现冲突时,以p为基础,产生另一个哈希地址p1,如果p1仍然冲突,再以p为基础,产生另一个哈希地址p2,…,直到找出一个不冲突的哈希地址pi,将相应元素存入其中。

再哈希法

这种方法是同时构造多个不同的哈希函数:

Hi=RH1 (key) i=1, 2, ..., k

当哈希地址Hi=RH1(key)发生冲突时,再计算Hi=RH2(key)......,直到冲突不再产生。这种方法不易产生聚集,但增加了计算时间。

链地址法

这种方法的基本思想是将所有哈希地址为i的元素构成一个称为同义词链的单链表,并将单链表的头指针存在哈希表的第i个单元中,因而查找、插入和删除主要在同义词链中进行。链地址法适用于经常进行插入和删除的情况。

建立公共溢出区

这种方法的基本思想是:将哈希表分为基本表和溢出表两部分,凡是和基本表发生冲突的元素,一律填入溢出表。

2018-05-24



三口先生

凸 4

最常用的方法就是线性再散列。即插入元素时,没有发生冲突放在原有的规则下的空槽下,发生冲突时,简单遍历hash表,找到表中下一个空槽,进行元素插入。查找元素时,找到相应的位置的元素,如果不匹配则进行遍历hash表。

然后就是我们非线性再散列,就是冲突时,再hash,核心思想是,如果产生冲突,产生一个新的hash值进行寻址,如果还是冲突,则继续。

上述的方法,主要的缺点在于不能从表中删除元素。

还有就是我们hashmap的思想外部拉链。

2018-05-24



公号-Java大后端

心 81

Hashtable、HashMap、TreeMap心得

三者均实现了Map接口,存储的内容是基于key-value的键值对映射,一个映射不能有重复的键,一个键最多只能映射一个值。

(1) 元素特性

HashTable中的key、value都不能为null; HashMap中的key、value可以为null,很显然只能有一个key为null的键值对,但是允许有多个值为null的键值对; TreeMap中当未实现 Comparator 接口时, key 不可以为null;当实现 Comparator 接口时,若未对null情况进行判

断,则key不可以为null,反之亦然。

(2)顺序特性

HashTable、HashMap具有无序特性。TreeMap是利用红黑树来实现的(树中的每个节点的值,都会大于或等于它的左子树种的所有节点的值,并且小于或等于它的右子树中的所有节点的值),实现了SortMap接口,能够对保存的记录根据键进行排序。所以一般需要排序的情况下是选择TreeMap来进行,默认为升序排序方式(深度优先搜索),可自定义实现Comparator接口实现排序方式。

(3)初始化与增长方式

初始化时: HashTable在不指定容量的情况下的默认容量为11,且不要求底层数组的容量一定要为2的整数次幂; HashMap默认容量为16,且要求容量一定为2的整数次幂。

扩容时:Hashtable将容量变为原来的2倍加1;HashMap扩容将容量变为原来的2倍。

(4)线程安全性

HashTable其方法函数都是同步的(采用synchronized修饰),不会出现两个线程同时对数据进行操作的情况,因此保证了线程安全性。也正因为如此,在多线程运行环境下效率表现非常低下。因为当一个线程访问HashTable的同步方法时,其他线程也访问同步方法就会进入阻塞状态。比如当一个线程在添加数据时候,另外一个线程即使执行获取其他数据的操作也必须被阻塞,大大降低了程序的运行效率,在新版本中已被废弃,不推荐使用。HashMap不支持线程的同步,即任一时刻可以有多个线程同时写HashMap;可能会导致数据的不一致。如果需要同步(1)可以用 Collections的synchronizedMap方法;(2)使用ConcurrentHashMap类,相较于HashTable锁住的是对象整体,ConcurrentHashMap基于lock实现锁分段技术。首先将Map存放的数据分成一段一段的存储方式,然后给每一段数据分配一把锁,当一个线程占用锁访问其中一个段的数据时,其他段的数据也能被其他线程访问。ConcurrentHashMap不仅保证了多线程运行环境下的数据访问安全性,而且性能上有长足的提升。

(5)一段话HashMap

HashMap基于哈希思想,实现对数据的读写。当我们将键值对传递给put()方法时,它调用键对象的hashCode()方法来计算hashcode,让后找到bucket位置来储存值对象。当获取对象时,通过键对象的equals()方法找到正确的键值对,然后返回值对象。HashMap使用链表来解决碰撞问题,当发生碰撞了,对象将会储存在链表的下一个节点中。 HashMap在每个链表节点中储存键值对对象。当两个不同的键对象的hashcode相同时,它们会储存在同一个bucket位置的链表中,可通过键对象的equals()方法用来找到键值对。如果链表大小超过阈值(TREEIFY_THRESHOLD, 8),链表就会被改造为树形结构。

2018-05-24

清风

凸 48

感觉每个知识点都很重要,但又点到为止,感觉读完不痛不痒,好像学到什么,但细想又没掌握什么,希望能够深入一点!

2018-07-05





amourling

மீ 18

提个意见,文章中请不要出现太多似乎,怀疑之类的必须,该是什么就是什么,不确定的不 要拿出来。

2018-07-11



小飞哥 超級會員

凸 10

总觉得还是不太深,只是每个map的区别。我觉得每个map的实现都能讲出很多问题来,在 面试时也经常碰壁,看完但也没觉得学到什么深入的地方

2018-07-20



j.c.

凸 9

这是面试必问题。什么时候也能讲讲红黑树的树化具体过程,那个旋转一直没搞懂。另外tre eifyBin这个单词的词面意思是什么?

2018-05-24



鲤鱼

公 8

读到最后链表树化刚准备开始飙车,结果突然跳车。树化讲细点更好

2018-05-29

作者回复

感谢反馈,最近几章篇幅都超标了......只能照顾大多数需求,抱歉 2018-05-29



xinfangke

凸 4

老师 如果hashmap中不存在hash冲突 是不是就相当于一个数组结构呢 就不存在链表了呢 2018-05-29

作者回复

我理解是

2018-05-29



coolboy

凸 3

removeEldestEntry这个方法是不是指移除最旧的对象,也就是按照最先被put进来的顺序, 而不是指不常访问的对象。

2018-06-24



代码狂徒

凸 3

针对负载因子,您所指的存太满会影响性能是指什么?毕竟已经开辟了相应内存空间的,没 什么不用呢?

2018-05-24

作者回复

冲突可能会增加,影响查询之类性能, 当然看具体的需求 2018-05-25



ሲን 2



老师我想问一下,hashmap明明继承了abstractmap,而abstractmap已经实现了map接口,为什么hashmap还要实现map接口呢?

2018-07-28



Darcy

凸 2

equals 的对称、反射、传递等特性。

这里的反射是不是写错了,应该是自反性,对称性,传递性,一致性等等

2018-07-28



李飞

凸 2

这个内容延展的好多,这要补多少天的功课,才能搞定☺

2018-06-02

作者回复

加油

2018-06-03



灰飞灰猪不会灰飞.烟灭

ம் 2

这是1.7的hashmap吧?

2018-05-24



Jerry银银

凸 2

我一直认为:JAVA集合类是非常好的学习材料。

如果敢说精通JAVA集合类,计算机功底肯定不会太差

2018-05-24



allean

凸 1

很开心能够阅读杨老师的专栏,收获很多。跟着杨老师的指引,一点点的深入,层层迷雾慢慢剥开,仔细思索顿时豁然开朗,这种感觉真是太好了!

有一个问题想请教杨老师,当链表长度达到阙值时,【容量】大于MIN_TREEIFY_CAPACITY 会触发树化改造,我有两个疑问,

1.【容量】是指单个桶的链表长度还是指元素数量,或者是指hashmap的initialCapacity呢?

2.MIN_TREEIFY_CAPACITY这个值是固定的还是计算出来的,如果是固定的是多少啊?如果是计算得来的,是如何计算得呢?

麻烦杨老师解答一下,非常感谢!

2018-08-15



沈琦斌

ഥ 1

老师,感觉最后讲为什么要树化的时候结尾有点突然。既然您说了树化本质上是个安全问题,那么树化以后怎么就解决安全问题了呢,这个我没有理解,谢谢。

2018-06-27

作者回复

这个树实现提供可靠的logn访问性能,哈希表好的时候比它强,问题是出在最差情况,退化成链表了

2018-06-27



zjh

ம் 1

受教了,把java集合的源代码掌握了,对java和数据结构的了解都会有很大的提升 2018-05-28



代码狂徒

凸 1

为什么不是一开始就树化,而是要等到一定程度再树化,链表一开始就是消耗查找性能啊? 另外其实不太明白为什么是0.75的负载因子,如果是.08或者0.9会有什么影响吗?毕竟已经开辟了相关内存空间

2018-05-24

作者回复

回复了,数据少的时候,平均访问长度很小,没必要麻烦;0.75是通用场景建议,取个平衡,具体看你调整它目标是什么了

2018-05-28